

```
# Manipulasi data
import pandas as pd
import numpy as np

# Visualisasi
import matplotlib.pyplot as plt
import seaborn as sns

# Preprocessing
from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split

# Model Random Forest
from sklearn.ensemble import RandomForestClassifier

# Evaluasi
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

# Baca file dataset
df = pd.read_csv('E-commerce Customer Behavior.csv')

df.head(10)
df.drop('Customer ID', axis=1, inplace=True)
df.info()

le = LabelEncoder() # Membuat objek LabelEncoder
df['Gender'] = le.fit_transform(df['Gender'])
df['City'] = le.fit_transform(df['City'])
df['Membership Type'] = le.fit_transform(df['Membership Type'])
df['Satisfaction Level'] = le.fit_transform(df['Satisfaction Level']) # Target
df.head()

# Tentukan fitur input secara eksplisit
X = df[['Gender', 'Age', 'City', 'Membership Type',

'Total Spend', 'Items Purchased', 'Average Rating',
'Discount Applied', 'Days Since Last Purchase']]

# Tentukan target output
y = df['Satisfaction Level']

# Step 1: Split 70% training, 30% temp (validation + testing)
X_train, X_temp, y_train, y_temp = train_test_split(X, y, test_size=0.3,
random_state=42)

# Step 2: Split 30% temp menjadi 15% validation, 15% testing
X_val, X_test, y_val, y_test = train_test_split(X_temp, y_temp,
test_size=0.5, random_state=42)

# Inisialisasi model Random Forest
model_rf = RandomForestClassifier(n_estimators=100, random_state=42)

# Latih model menggunakan data training
model_rf.fit(X_train, y_train)

# Evaluasi model pada data validation
```

```
# Evaluasi model pada data validation
y_val_pred = model_rf.predict(X_val)

print("Validation Accuracy:", accuracy_score(y_val, y_val_pred))
print("Validation Report:\n", classification_report(y_val, y_val_pred))

# Evaluasi akhir pada data testing
y_test_pred = model_rf.predict(X_test)

print("Test Accuracy:", accuracy_score(y_test, y_test_pred))

print("Test Report:\n", classification_report(y_test, y_test_pred))

importances = model_rf.feature_importances_
features = X.columns

plt.figure(figsize=(10,6))
sns.barplot(x=importances, y=features, palette='viridis')
plt.title('Feature Importance - Random Forest')
plt.xlabel('Importance Score')
plt.ylabel('Fitur')
plt.show()
```

a. Sebutkan dan jelaskan kelebihan-kelebihan Random Forest dibandingkan Decision Tree!

Jawaban : Random Forest adalah algoritma supervised learning untuk klasifikasi dan regresi yang bekerja dengan membangun banyak decision tree. Setiap pohon menganalisis data acak, lalu hasilnya digabung dengan voting klasifikasi atau averaging regresi. Teknik ensemble ini meningkatkan akurasi dan mengurangi kesalahan.

b. Apa fungsi dari parameter `n_estimators` dalam Random Forest?

Jawaban : Parameter `n_estimators` digunakan untuk menentukan jumlah pohon (Decision Tree) Jika jumlah lebih banyak maka model lebih stabil dan akurat karena hasil prediksi rata-rata/voting lebih konsisten. Tapi, semakin banyak jumlah pohon maka waktu komputasi juga semakin lama.

c. Jelaskan tentang teknik bagging di dalam algoritma Random Forest!

Jawaban : Teknik bagging di Random Forest digunakan untuk membuat banyak pohon keputusan dengan data latih yang berbeda.

1. Dari dataset asli, dibuat beberapa sampel acak dengan metode bootstrap.
2. Setiap sampel dipakai untuk melatih satu pohon keputusan.
3. Hasil dari semua pohon kemudian digabungkan: Hasilnya Jika Hasil Voting mayoritas digunakan untuk klasifikasi, sedangkan rata-rata untuk regresi. Dengan bagging bisa

mengurangi overfitting dan membuat prediksi lebih stabil karena keputusan tidak hanya bergantung pada satu pohon saja, melainkan gabungan banyak pohon.
Data columns (total 10 columns):

d. Jelaskan tentang perbedaan akurasi dan presisi pada konteks klasifikasi!

Jawaban : Akurasi adalah mengukur seberapa banyak prediksi yang benar dibandingkan dengan semua prediksi. Presisi adalah mengukur seberapa tepat model saat memprediksi positif.

e. Lihat hasil dari langkah ke 17 diatas. Apa yang bisa anda jelaskan dari hasil tersebut?

Jawaban :

- Fitur dengan nilai Importance tertinggi adalah yang paling berpengaruh terhadap keputusan model.
- Fitur dengan nilai rendah memiliki kontribusi kecil, bahkan mungkin bisa dipertimbangkan untuk dihapus (feature selection) agar model lebih sederhana.
- Random Forest menghitung importance berdasarkan berapa besar pengurangan impurity setiap kali fitur digunakan dalam pohon.

Start coding or generate with AI.

	0	1	2	3
macro avg	1.00	1.00	1.00	52
weighted avg	1.00	1.00	1.00	52

Test Accuracy: 1.0

Test Report:

	precision	recall	f1-score	support
0	1.00	1.00	1.00	26
1	1.00	1.00	1.00	11
2	1.00	1.00	1.00	16
accuracy			1.00	53
macro avg	1.00	1.00	1.00	53
weighted avg	1.00	1.00	1.00	53

/tmp/ipython-input-2022382709.py:73: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.1

```
sns.barplot(x=importances, y=features, palette='viridis')
```

